2026

Fundamentos de la Ciencia de Datos

Trabajo Práctico Especial

Grupo N°: 3

Tonelotto Valentin

Gonzalez Franco Naim

Ellehoj Alex

Índice

1. Introducción

    1.1 Contexto

    1.2 Descripción de los datos

    1.3 Problemáticas identificadas y preprocesamiento

    1.4 Organización del informe

2. Análisis exploratorio de los datos

3. Hipótesis y resolución

    3.1 Hipótesis 1

    3.2 Hipótesis 2

    3.3 Hipótesis 3

    3.4 Hipótesis 4

    3.5 Hipótesis 5

    3.6 Hipótesis 6

4. Conclusiones

Referencias

1.Introducción:

1.1 Contexto:

En este dataset se nos presentaron datos y variables que representan el funcionamiento de los riñones, estos mismos son vitales para ciertas funciones humanas, tales como: filtrado de la sangre, equilibrio de electrolitos, regulación del volumen de agua. En ocasiones este órgano puede estar desregulado, si esto sucede por un tiempo prolongado, puede derivar en enfermedad renal crónica (**CKD**).

De esta manera podemos identificar de manera temprana los factores de riesgo demográficos, antropométricos (como el índice de masa corporal o la presión arterial) y de estilo de vida (como el tabaquismo o el ingreso de dinero en el hogar) resulta fundamental para comprender qué condiciones favorecen el desarrollo y agravamiento del deterioro renal.

A lo largo de la realización del trabajo tuvimos que buscar en internet la gran mayoría de las biovariables y que efecto tenían en el cuerpo. Además pudimos encontrar que significaban las siglas **NHANES**, que significa *National Health and Nutrition Examination Survey*. Y que la realiza el **NCHS** (Centro Nacional de Estadísticas de Salud).

1.2 Descripción de los datos:

Este trabajo analiza el conjunto de datos de **CKD_NHANES** este, recopila información de una encuesta poblacional de salud y nutrición realizada en Estados Unidos entre los años 2021 y 2023. Cada registro representa a un participante único examinado e integra un total de 29 atributos,los cuales se pueden separar en cuatro categorías:

- **Datos demográficos y socioeconómicos:** edad (age), sexo (gender), etnicidad (ethnicity), nivel educativo (education_level) y relación de ingresos respecto al umbral de pobreza (poverty_income_ratio).

- **Medidas corporales y signos vitales:** peso (weight_kg), altura (height_cm), índice de masa corporal (bmi) y presión arterial sistólica y diastólica (bp_systolic, bp_diastolic).

- **Análisis de laboratorio (sangre y orina):** biomarcadores como creatinina sérica y urinaria, nitrógeno ureico, albúmina, fósforo, bicarbonato, calcio y ácido úrico.

- **Antecedentes declarados y variables derivadas:** diagnóstico de diabetes, uso de insulina o medicación oral, historial de tabaquismo, tasa **egfr**, etapa de

la enfermedad (**ckd_stage**, clasificada del estadio 1 al 5) y la etiqueta binaria indicadora de presencia de enfermedad renal (**ckd_present**).

A continuación, se presenta un link con una tabla de cada variable con que tipo es, además, con que tipo de dato se representa dentro del dataset original.

TPE Fundamentos tabla variables

1.3. Problemáticas identificadas y preprocesamiento

Durante la inspección preliminar del dataset detectamos diversas inconsistencias técnicas y semánticas, por las cuales tuvimos que aplicar técnicas de limpieza:

1. **Inadecuación de tipos de datos:** Variables cuantitativas discretas y categóricas codificadas numéricamente (como **participant_id**, **age**, **education_level**, **bp_systolic**, **bp_diastolic** y variables de antecedentes) se encontraban almacenadas en formato de punto flotante (**Float64**), por lo que fueron estandarizadas a tipos enteros (**Int64**) o categóricos como correspondiera (notebook: «Limpieza de datos → Conversión de columnas a enteros»).
2. **Codificación de valores faltantes:** Siguiendo las convenciones del cuestionario NHANES, las respuestas codificadas con los valores **7** (*se negó a responder*) y **9** (*no sabe*) en variables como education_level, **current_smoker**, **ever_smoked**, **diabetes_diagnosed** y **diabetes_pills** fueron transformadas a valores nulos (**NaN**) para evitar ruido en el análisis posterior de las variables (notebook: «Limpieza de datos → Códigos de falta de respuesta (7 y 9)»).
3. **Control de integridad y rangos biológicos:** Se verificó la inexistencia de filas o identificadores duplicados y fuimos probando que la información que teníamos a nuestra disposición de los biomarcadores no tuvieran datos irreales, como por ejemplo, que no haya otro **gender** dentro del dataset que no sea Male o Female o que una persona no mida más de 240 cm. También en variables como la presión diastólica por ejemplo buscamos en internet cual seria el limite que un humano puede soportar y buscamos si existe alguna fila que contuviera ese límite o más, adaptamos ese modus operandi con todas las variables para comprobar la correctitud de los datos (notebook: «Limpieza de datos → Verificación de valores fuera de rango» y «Registros duplicados»).

4. **Valores faltantes de eGFR (etapa Unknown):** el 46,99 % de los registros (5.607 de 11.933) no tiene el eGFR calculado y figura con ckd_stage = Unknown. Antes de decidir qué hacer con ellos, revisamos cuál de las tres variables que se usan para calcular el eGFR (creatinina sérica, edad y sexo) era la que faltaba: en los 5.607 casos falta la creatinina sérica, mientras que la edad y el sexo están completos. Además, no existe ningún registro que tenga creatinina y no tenga eGFR, por lo que no hay ningún valor que podamos recalcular.

   Decidimos no imputar estos datos por tres motivos. Primero, imputar el eGFR implicaría inventar el resultado de un análisis de sangre que nunca se hizo: 2.545 de estos registros son menores de 12 años, a quienes NHANES no les

realiza ese análisis, y en el resto el dato de creatinina no está disponible. Segundo, el eGFR es justamente la variable que define la etapa de la enfermedad (ckd_stage) y su presencia (ckd_present), por lo que imputarlo sería inventar el diagnóstico que queremos analizar. Tercero, se trata de casi la mitad de la base, así que cualquier valor imputado (por ejemplo, la media) tendría un peso enorme y sesgaría los resultados. A esto se suma que, según la metadata, estos registros vienen codificados con ckd_present = 1: si los dejáramos, contaríamos como enfermas a 5.607 personas sin diagnóstico. Por estos motivos, los excluimos de todos los análisis que usan el eGFR o la etapa de CKD (hipótesis 3.2 a 3.6). Este análisis se encuentra en la sección «Limpieza de datos → Valores faltantes de eGFR» de la notebook.

1.4. Organización del informe

El resto del documento se estructura de la siguiente manera: en la **Sección 2** se desarrolla el análisis exploratorio de datos (EDA). En la **Sección 3** se presenta el planteo, la estrategia metodológica y la validación estadística de seis hipótesis de estudio. Por último, en la **Sección 4** se exponen las conclusiones generales del trabajo.

2. Análisis exploratorio de los datos

Para comprender las características principales de nuestra población de estudio, primero nos concentramos en la distribución de las variables. Como inicio, decidimos analizar la distribución de participantes con CKD presente, además, ver en qué etapa se presentan. Esto debido a que si el paciente presenta un stage 5 de **ckd_stage**, la enfermedad pasa a nombrarse como **CKF** (*Chronic kidney failure*). Esto se puede apreciar en la *figura 2.1.*

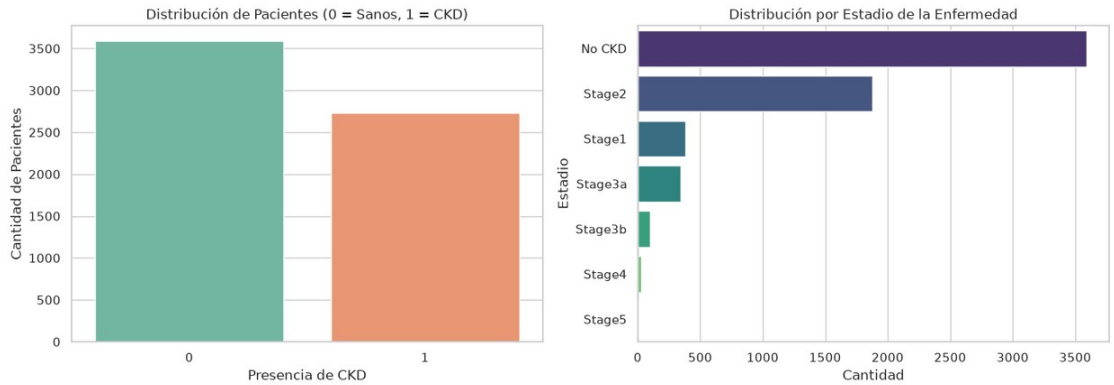


Figura 2.1: Cantidad de participantes según presencia de CKD (izquierda) y según etapa de la enfermedad (derecha), sin los registros Unknown.

En la *figura 2.2* se pueden apreciar las distribuciones univariadas de las principales mediciones clínicas y demográficas continuas y discretas. Se destacan variables como la presión sistólica (**bp_systolic**) y el Índice de Masa Corporal (**bmi**) presentan una marcada asimetría hacia la derecha. Por otro

lado, la distribución de la edad muestra 2 grandes proporciones de los participantes, una parte se concentra en el rango de niños y jóvenes hasta 20 años, mientras que la segunda corresponde adultos mayores a 60 años, pero no superando los 80 años. El resto de los participantes del estudio se encuentran entre 20 y 60 años

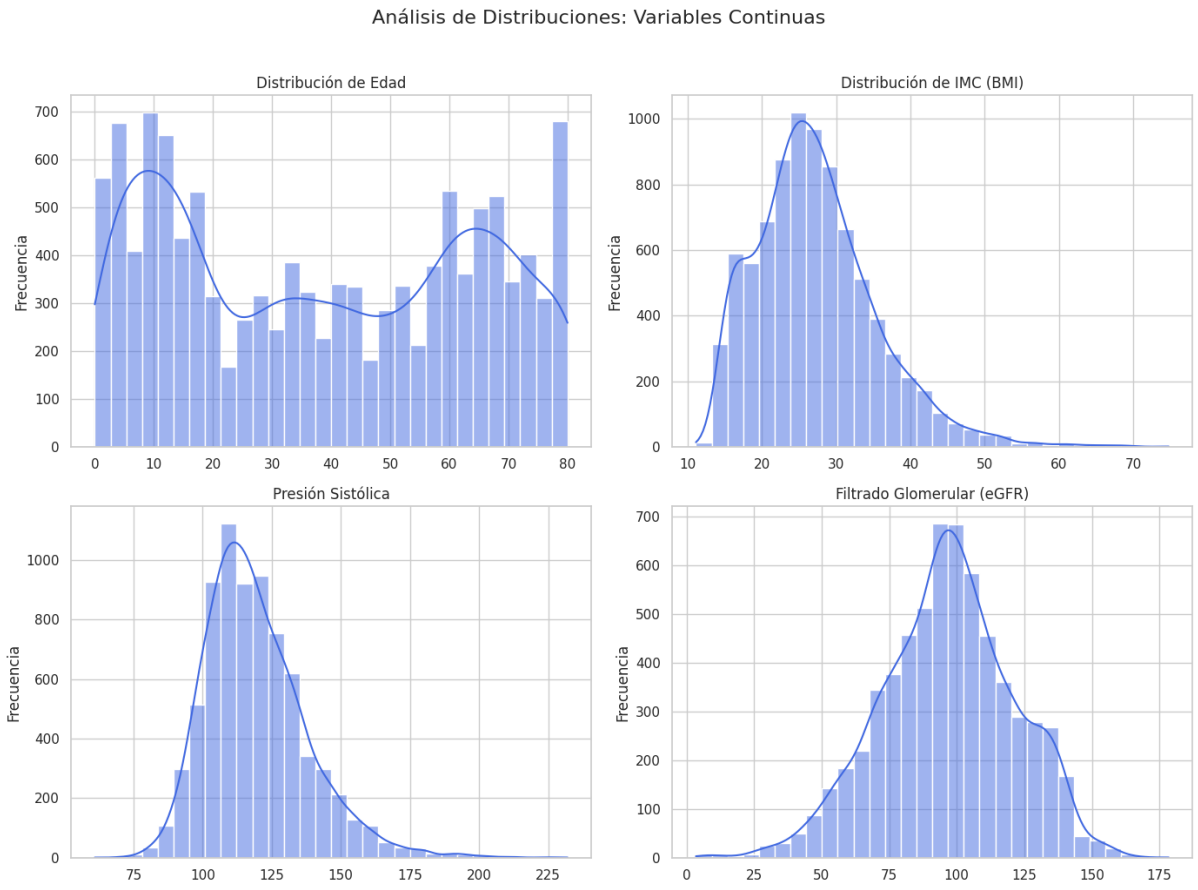


Figura 2.2: Histogramas de la edad, el BMI, la presión sistólica y el eGFR.

Por último, la *figura 2.3* resume las frecuencias de las variables categóricas clave para nuestro análisis. Si bien la muestra se encuentra relativamente equilibrada en términos de género, observamos un fuerte desbalance en el diagnóstico de diabetes (**diabetes_diagnosed**), donde predominan los casos negativos.

A pesar de este desbalance global, visualmente surge la sospecha de que la minoría de pacientes con diabetes diagnosticada podría estar sobrerrepresentada dentro del grupo con falla renal. Esto debido a que la literatura médica establece un vínculo estrecho entre los niveles de glucosa y el daño en los riñones.

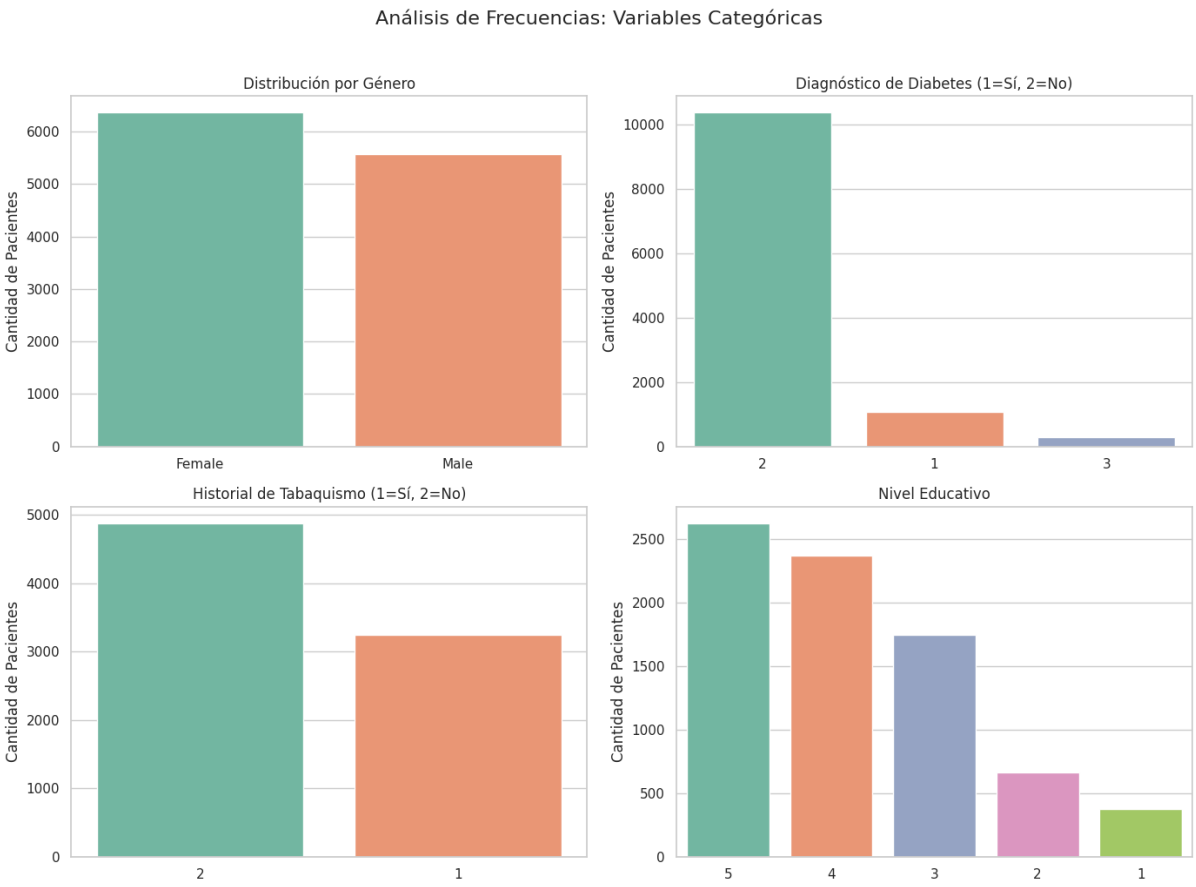


Figura 2.3: Frecuencias de sexo, diagnóstico de diabetes, tabaquismo y nivel educativo.

En la notebook, estos gráficos se encuentran en la sección «Análisis exploratorio de los datos», subsecciones «Presencia y etapas de CKD», «Distribución de las variables continuas» y «Frecuencia de las variables categóricas».

3. Hipótesis y resolución

3.1 Hipótesis 1: el porcentaje de fumadores actuales de cigarrillo entre los adultos del dataset (NHANES 2021-2023) supera el porcentaje de fumadores adultos de EE.UU. informado por el CDC.

3.1.1 Definición de la hipótesis:

En la primera hipótesis univariada propuesta, vamos a evaluar si la cantidad de personas dentro del dataset (NHANES 2021-2023) supera el porcentaje de fumadores adultos de EE.UU. informado por el CDC, el cual es de 11,5%.

Lo que nos motivó a plantear esta hipótesis surge a partir de que el tabaquismo es un factor de estilo de los más perjudiciales para la función renal, no lo hace de forma directa pero influye en la circulación sanguínea y agrava casos de hipertensión.

Para validarlo mediante un test de hipótesis planteamos lo siguiente:

H0: $p = 0.115$ (el porcentaje de fumadores del dataset es igual al de EE.UU.)

H1: $p > 0.115$ (el porcentaje de fumadores del dataset supera al de EE.UU.)

Nivel de significancia**:** $\alpha = 0.05$

3.1.2 Estrategia de abordaje:

Antes de realizar el test adecuado filtramos la información disponible, primero revisamos la población observada tomando únicamente a las personas que respondieron válidamente 1 o 2 en la columna **ever_smoked,** comprobando también que la edad mínima de este grupo sea 18 años. Con esta base creamos la variable **fumador**, la cual tiene de valor 1 si la persona fuma actualmente (current_smoker igual a 1 o 2) y 0 en el caso contrario.

El test que elegimos fue el test t ya que este nos pareció el más apropiado debido a que se encarga de comparar la media de una variable con una fija. Al haber planteado la variable **fumador** sabemos con exactitud que la media se va a tratar de la proporción de fumadores. Comparamos la media de esta variable con el valor fijo de referencia $p=0.115$.

Respecto a los supuestos del test, en primer lugar asumimos la independencia de los datos. En cuanto al supuesto de normalidad, no es necesario realizar su análisis dado que se trata de una variable dicotómica (0/1), por lo que carece de sentido evaluar su distribución mediante pruebas como Shapiro-Wilk. Sin embargo, dado que contamos con un tamaño muestral sumamente amplio ($n = 8121$) y amparándonos en el Teorema Central del Límite, sabemos que la media muestral se distribuye de manera aproximadamente normal, lo que

valida la aplicación del test t. Por último, la homocedasticidad no requiere verificación al evaluar a un solo grupo contra un valor fijo.

En la notebook, este análisis se encuentra en la sección «Análisis de la hipótesis univariada», subsecciones «Población observada», «Test t para una muestra» y «Gráfico: proporción del dataset».

3.1.3 Resultados obtenidos y discusión:

Al contabilizar los datos sobre el total de 8.121 adultos observados, obtuvimos que 1.190 son fumadores y 6.931 no fuman actualmente, lo que representa un **14,65%** de fumadores activos en el dataset frente al **11,5%** de referencia del CDC.

Al correr el test t para una muestra, obtuvimos los siguientes valores:

- **Estadístico t:** t = 8.035 (lo que nos indica que la proporción del dataset está más de 8 errores estándar por encima del valor del CDC).
- **Grados de libertad:** df = 8120.
- **p-valor:** p = 5.33e-16.
- **Límite inferior del IC del 95% (unilateral):** 14,01%.

Para la visualización de los datos optamos por un gráfico de barras en la *figura 3.1*, ya que es la forma más óptima de mostrar variables entre categorías.

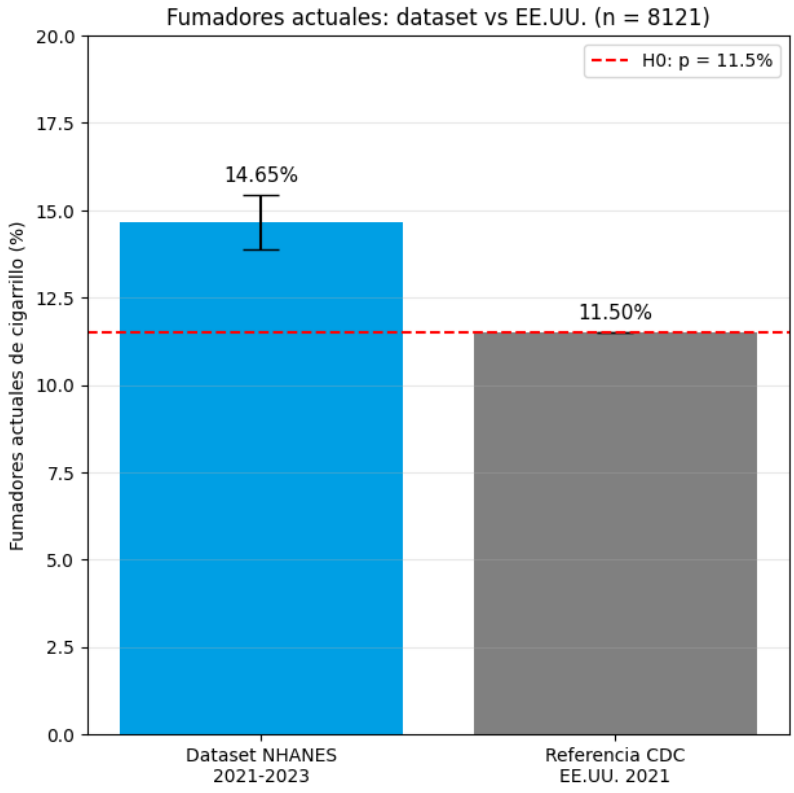


Figura 3.1: Porcentaje de fumadores actuales del dataset, con su IC del 95 %, frente al 11,5 % informado por el CDC (línea roja).

Para concluir, podemos decir que dado a que el p-valor obtenido (p = 5.33e-16) es muchísimo menor que el nivel de significancia α = 0.05, se rechaza la hipótesis nula **(H0)** y se confirma nuestra hipótesis:

Existe evidencia estadística suficiente para afirmar que el porcentaje de fumadores activos en los adultos del dataset supera significativamente el promedio nacional informado por el CDC. Esto nos muestra que la población relevada tiene una exposición alta al tabaco, un dato importante a tener en cuenta al evaluar el deterioro renal en las siguientes secciones.

3.2 Hipótesis 2: Existen diferencias en la capacidad de filtrado entre hombres y mujeres.

3.2.1 Definición de la hipótesis:

En esta hipótesis bivariada queremos comprobar si existen diferencias entre la tasa de filtrado de los riñones (**eGFR**) entre hombres y mujeres (**gender**).

Lo que nos llevó a plantear esta hipótesis es que los hombres por razón biológica tienen más masa muscular, por lo tanto, tienen más creatinina en sangre, permitiéndonos saber si este factor influye en la capacidad de filtrado.

H0: No existen diferencias significativas entre la distribución de la capacidad de filtrado (eGFR) de hombres y mujeres

H1: Existen diferencias significativas entre la distribución de la capacidad de filtrado (eGFR) de hombres y mujeres

Nivel de significancia**:** $\alpha = 0.05$

3.2.2 Estrategia de abordaje:

Para la evaluación de esta hipótesis, primero filtramos la población tomando en cuenta las personas que cuentan con un **eGFR** calculado y que son mayores a 18 años, esto lo hacemos para dejar de lado los encuestados los cuales tienen "unknown" y menores de edad. Luego de aplicar estos filtros nos quedamos con 2568 **Male** y 3090 **Female**.

Primero hicimos una exploración visual armando un boxplot (figura 3.2) para comparar las medianas, la dispersión y los valores atípicos de cada sexo. Luego, para elegir el test estadístico correcto, pusimos a prueba los dos supuestos paramétricos:

Normalidad: Evaluamos si los datos seguían una distribución normal mediante Shapiro-Wilk y luego completamos con un QQ-Plot para ambos géneros (figura 3.3 y 3.4).

Como podemos observar, en el principio y final de los gráficos se apartan de la línea, por lo tanto podemos decir que no es normal.

Homocedasticidad: para evaluar las varianzas utilizamos test de Levene, esto debido a que el test F de Fisher es menos robusto cuando los datos no son normales.

Dado a que ambos supuestos fallaron, nos decantamos por el test de Kruskal-Wallis, el cual trabaja con los rangos de observaciones en lugar de los valores crudos.

En la notebook, este análisis se encuentra en la sección «Análisis de la hipótesis bivariada», subsecciones «Población analizada», «Análisis gráfico de la hipótesis», «Supuesto 1: normalidad», «Supuesto 2: homocedasticidad» y «Elección del test».

3.2.3 Resultados obtenidos y discusión:

Al calcular las medidas descriptivas de ambos grupos con el boxplot (Figura 3.2), vimos que las mujeres presentan una media de eGFR aproximada de 93,01 mL/min/1,73 m² , mientras que los hombres tienen una media de 91,33 mL/min/1,73 m². Como se observa en el boxplot de la Figura 3.2, las dos cajas son muy parecidas: la mediana de las mujeres es apenas superior a la de los hombres y los bigotes casi se superponen, mostrando además varios *outliers* en la parte inferior que corresponden a pacientes con filtrado muy bajo.

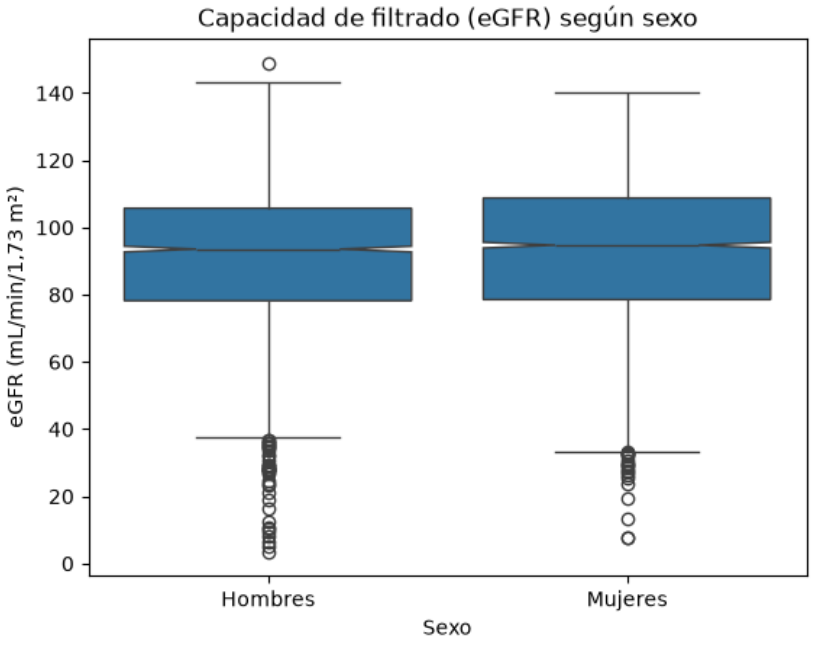


Figura 3.2: Boxplot del eGFR según sexo, en adultos con eGFR calculado.

A la hora de verificar los supuestos estos fueron los datos obtenidos:

Prueba de normalidad: El test de Shapiro-Wilk arrojó un estadístico de W = 0.983 (p-valor < 0.001) para los hombres y de W = 0.987 (p-valor < 0.001) para las mujeres. Como ambos valores son menores a α = 0.05, se rechaza la normalidad. Esto se confirma en los gráficos QQ plot (Figura. 3.3 y Figura 3.4), donde los puntos se desvían claramente de la línea roja teórica en ambos

extremos, sobre todo abajo a la izquierda por la cola larga de pacientes con bajo filtrado.

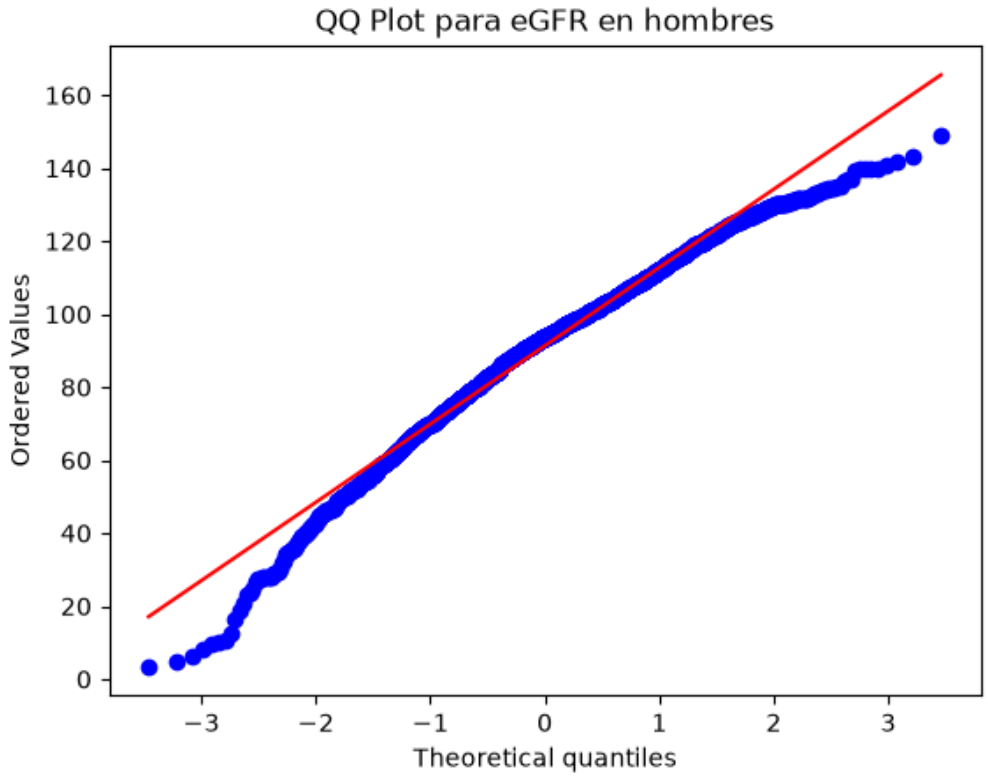


Figura 3.3: QQ plot del eGFR en hombres.

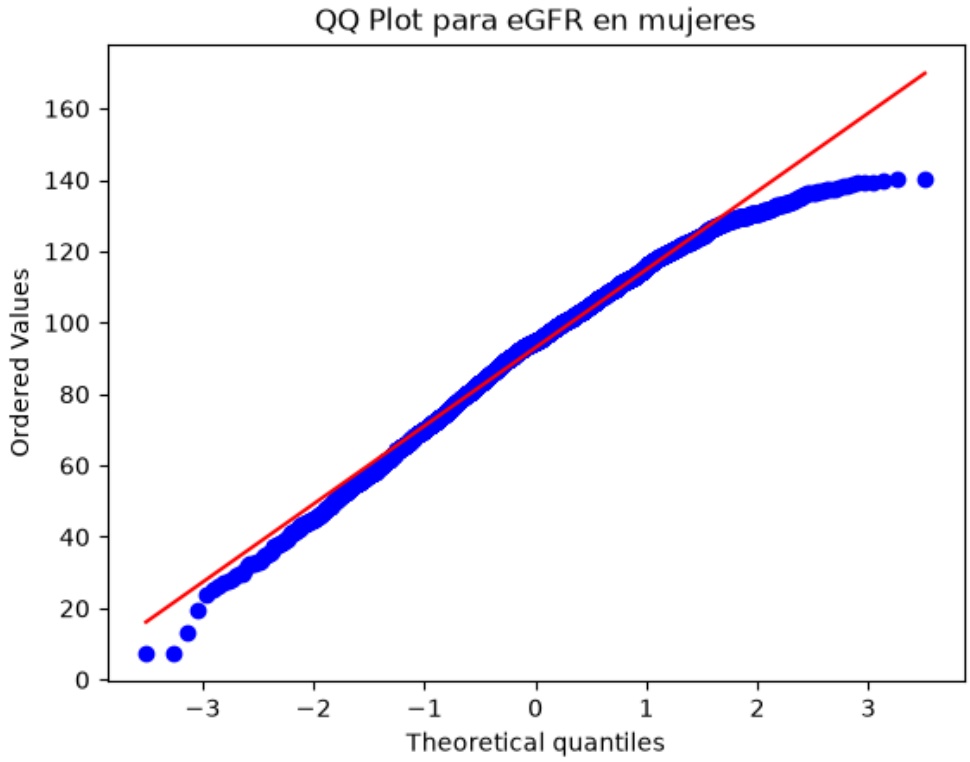


Figura 3.4: QQ plot del eGFR en mujeres.

Prueba de homocedasticidad: El test de Levene dio un estadístico de W = 4.955 con un p-valor = 0.026. Al ser menor a α = 0.05, también rechazamos la igualdad de varianzas entre hombres y mujeres.

Finalmente, al correr el **test de Kruskal-Wallis**, obtuvimos un estadístico H = 7.992 y un **p-valor = 0.0047**.

Como el p-valor es menor al nivel de significancia α = 0.05, se rechaza la hipótesis nula (H0) y se confirma nuestra hipótesis:

Existen diferencias estadísticamente significativas en la capacidad de filtrado entre hombres y mujeres, siendo la mediana de las mujeres levemente más alta (94,73 vs. 93,56). Sin embargo, una diferencia de apenas 1,17 mL/min/1,73 m² es muy chica desde el punto de vista médico y no alcanza para cambiar de etapa renal a ningún paciente. Por lo tanto, concluimos que la diferencia que queda es estadísticamente significativa, pero de poca relevancia práctica en el ámbito clínico.

3.3 Hipótesis 3: Existe un vínculo directo entre el eGFR, la relación albúmina/creatinina en orina, el ácido úrico, el fósforo, el bicarbonato y el BMI con la probabilidad de tener diabetes diagnosticada.

3.3.1 Definición de la hipótesis:

En esta tercera hipótesis (la multivariada propuesta por nuestro grupo), buscamos evaluar si existe un vínculo directo entre los marcadores principales de función y daño renal (**egfr**, **albumin_creatinine_ratio** o **ACR**), otros biomarcadores sanguíneos regulados por el riñón (**uric_acid**, **phosphorus**, **bicarbonate**) y el índice de masa corporal (**bmi**) con la probabilidad de que un paciente tenga diabetes diagnosticada.

Lo que nos motivó a plantear esta hipótesis es que la literatura médica señala a la diabetes como una de las causas principales del deterioro renal. Por eso, analizaremos mediante un modelo multivariado qué indicadores bioquímicos y renales se asocian a los pacientes diabéticos, y cómo esto se conecta con las distintas etapas de daño en el riñón.

Para validarlo mediante una **regresión logística** (con un nivel de significancia α = 0.05), planteamos lo siguiente para cada variable:

- **H0:** La variable no tiene un vínculo significativo con la probabilidad de tener diabetes diagnosticada (su *odds ratio* es igual a 1).
- **H1:** La variable tiene un vínculo significativo con la probabilidad de tener diabetes diagnosticada (su *odds ratio* es distinto de 1).

3.3.2 Estrategia de abordaje:

Para llevar adelante este análisis, definimos como variable objetivo binaria a **diabetes**, que toma valor 1 si la persona tiene diabetes diagnosticada (**diabetes_diagnosed** == 1) y 0 si no la tiene. Filtramos la población tomando a los adultos de 18 años o más que contaban con todas las mediciones de laboratorio completas, quedando una muestra limpia de 5.476 adultos, de los cuales 727 (el 13,28%) tienen diabetes diagnosticada y 4.749 no.

Inclusión de la edad (**age**) como variable de control: Observamos que las personas diabéticas de la muestra son bastante mayores que las no diabéticas, y sabemos que el **egfr** disminuye naturalmente con la edad porque forma parte de su fórmula. Incluir la edad nos permite controlar esta confusión para no atribuirle al **egfr** un efecto que en realidad es por los años del paciente.

Exclusión de **urine_albumin**: No la pusimos por separado porque ya está contenida dentro del cálculo del ACR (albumin_creatinine_ratio), evitando duplicar información.

Elección de **bmi** en lugar de **weight_kg**: Usamos el IMC porque corrige el peso en función de la altura de la persona.

Primero analizamos una matriz de correlación (*Figura 3.5*), verificamos que no existiera **multicolinealidad** mediante el cálculo del **VIF**, estandarizamos todas las variables predictoras con StandardScaler para hacerlas comparables, ajustamos la regresión logística y calculamos los **Odds Ratios** con sus intervalos de confianza al 95%. Finalmente, cruzamos el diagnóstico de diabetes con las etapas de **ckd_stage** y la presencia de albuminuria mediante tablas de contingencia.

En la notebook, este análisis se encuentra en la sección «Análisis de la hipótesis multivariada», subsecciones «Variable objetivo y población», «Análisis exploratorio: matriz de correlación», «Multicolinealidad: VIF», «Estandarización de las variables», «Regresión logística», «Odds ratios», «¿Por qué incluimos la edad?» y «Relación con el daño renal y la CKD».

3.3.3 Resultados obtenidos y conclusiones:

En la exploración inicial mediante la matriz de correlación (*Figura 3.5*), observamos que las variables con mayor correlación individual frente a

diabetes son la edad (r = 0.23), el BMI (r = 0.18), el **egfr** (r = -0.18, indicando menor filtrado en diabéticos) y el ACR (r = 0.14), mientras que entre los predictores se destaca una fuerte correlación negativa entre **egfr** y **age** (r = -0.70). A pesar de esto, la prueba de **VIF** arrojó valores inferiores a **2,2** para todas las variables, descartando problemas de multicolinealidad.

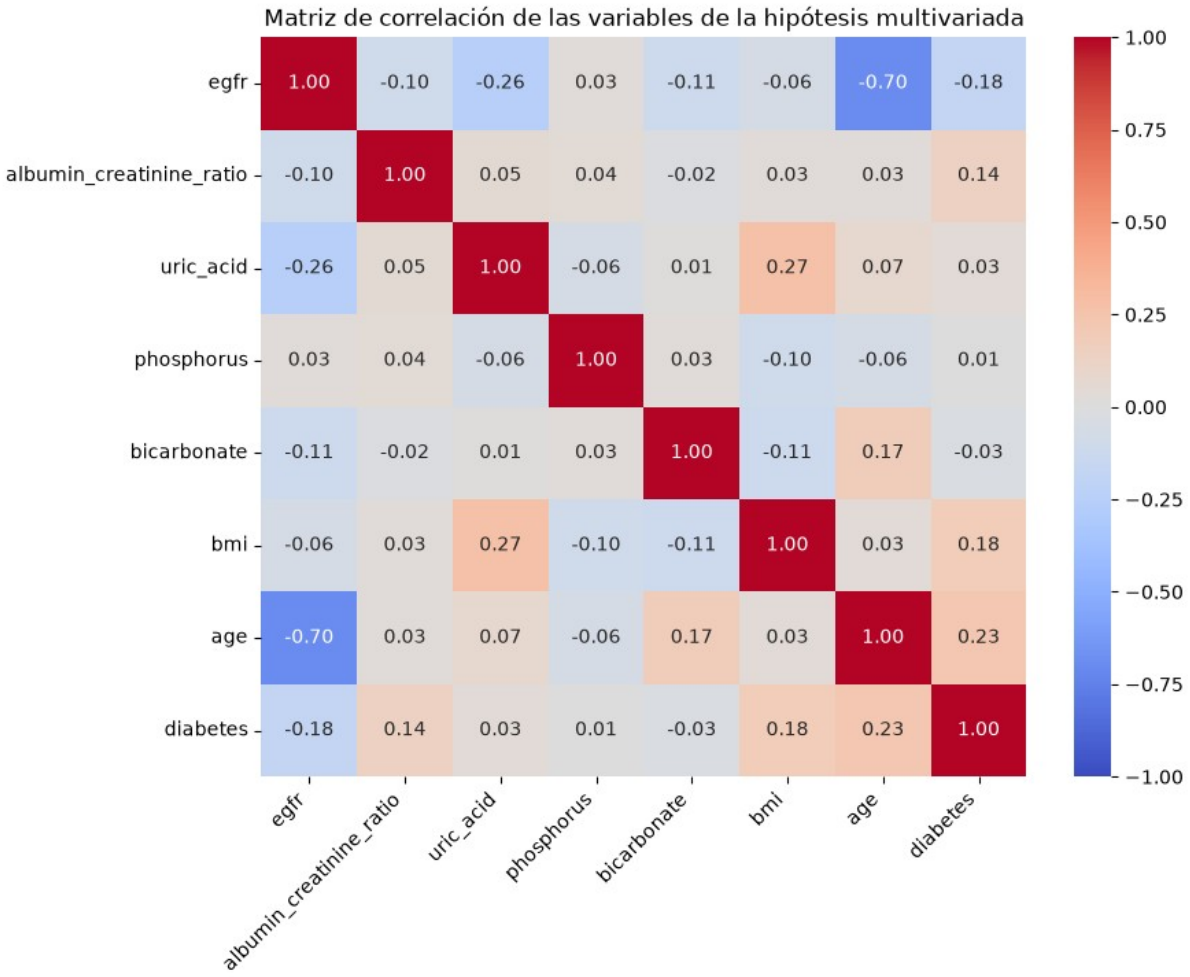


Figura 3.5: Matriz de correlación entre la diabetes y las variables de la hipótesis multivariada.

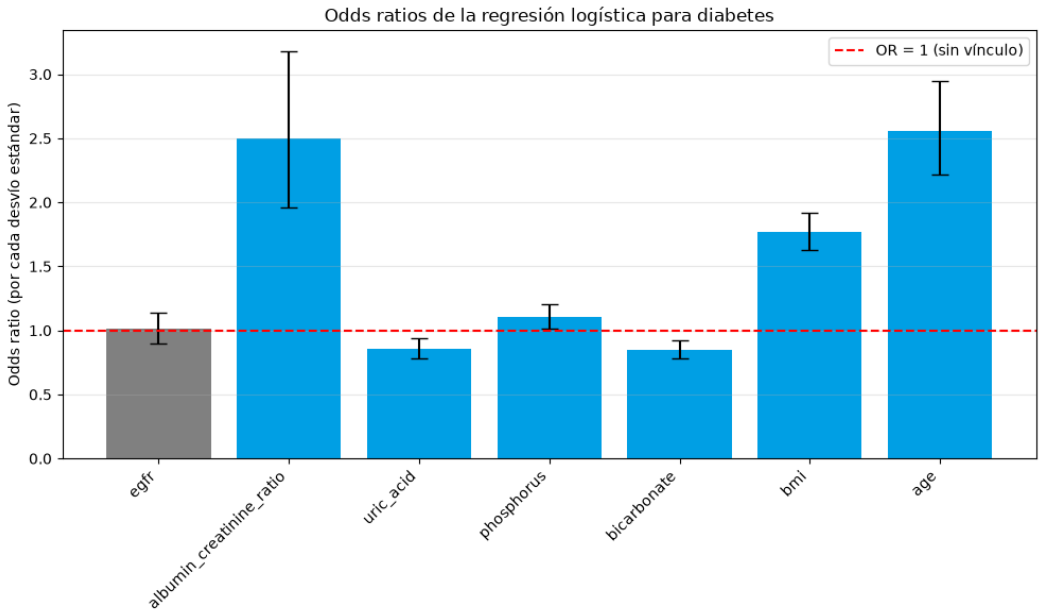


Figura 3.6: Odds ratios (por desvío estándar) del modelo de diabetes, con su IC del 95 %. En azul, las variables significativas.

Dep. Variable:	diabetes	**No. Observations:**	5476
Model:	Logit	**Df Residuals:**	5468
Method:	MLE	**Df Model:**	7
Date:	Tue, 10 Nov 2026	**Pseudo R-squ.:**	0.1494
Time:	13:06:17	**Log-Likelihood:**	-1824.1
converged:	True	**LL-Null:**	-2144.4
Covariance Type:	nonrobust	**LLR p-value:**	4.361e-134

	coef	std err	z	P> |z|	[0.025	0.975]
const	-2.2649	0.055	-40.850	0.000	-2.374	-2.156
egfr	0.0114	0.061	0.188	0.851	-0.108	0.131
albumin_creatinine_ratio	0.9149	0.124	7.377	0.000	0.672	1.158
uric_acid	-0.1535	0.047	-3.247	0.001	-0.246	-0.061
phosphorus	0.0998	0.044	2.277	0.023	0.014	0.186
bicarbonate	-0.1622	0.043	-3.740	0.000	-0.247	-0.077
bmi	0.5712	0.042	13.711	0.000	0.490	0.653
age	0.9384	0.072	13.022	0.000	0.797	1.080

Tabla 1: Resumen de la regresión logística para la diabetes diagnosticada.

Al ajustar el modelo de regresión logística (*Tabla 1*), la hipótesis se confirma parcialmente, hallando que cinco de las seis variables estudiadas tienen un vínculo estadísticamente significativo con la diabetes una vez ajustadas por la edad (*Figura 3.6*):

- Relación albúmina/creatinina en orina **(albumin_creatinine_ratio - ACR):** Es el marcador más fuerte: un aumento de un desvío estándar en la albuminuria multiplica por 2,5 las chances de que el paciente sea diabético.
- Índice de Masa Corporal **(bmi):** Por cada 7 kg/m² adicionales, las chances de presentar diabetes aumentan un 77%.
- Fósforo sérico **(phosphorus):** Cada 0,5 mg/dL extra incrementa las chances en un 11%.
- Bicarbonato **(bicarbonate):** Actúa de forma inversa: niveles más altos se asocian a un 15% menos de chances (es decir, los diabéticos tienden a presentar bicarbonato más bajo).
- Ácido úrico **(uric_acid):** Muestra que, a igual BMI, los pacientes con diabetes diagnosticada tienen niveles de ácido úrico levemente menores (posiblemente porque el exceso de glucosa en orina favorece la excreción renal de ácido úrico).

En cambio, el filtrado glomerular (**egfr**) no presenta un vínculo significativo cuando se controla por la edad. Al hacer la prueba de ajustar exactamente el mismo modelo quitando la variable **age**, el **egfr** parecía muy significativo, esto demuestra que los diabéticos de la muestra tienen menor **egfr** simplemente porque son personas más ancianas, y no por un efecto directo aislado.

Por último, al cruzar estos resultados con las etapas de enfermedad renal en adultos, encontramos un hallazgo clínico clave que conecta todo el trabajo:

- El 32,0% de los diabéticos presenta albuminuria (ACR >= 30 mg/g), frente a sólo el 8,3% de los no diabéticos.
- Como consecuencia, los diabéticos están mucho más representados en **Stage1** y en las etapas avanzadas **Stage3 a Stage5** (20,6% vs. 6,5%), mientras que en **Stage2** no hay diferencias (34,0% vs. 33,0%).

Esto explica por qué en la Hipótesis 3.6 la diabetes no había dado significativa sobre **ckd_present**: como la gran mayoría de los casos positivos de **ckd_present** son **Stage2**, el verdadero impacto de la diabetes quedaba oculto en el promedio general. En conclusión, de los dos ejes renales, la diabetes se vincula directamente con el daño temprano en la barrera de filtración antes de que baje el filtrado (**egfr**). Como limitaciones, recordamos que el modelo mide asociación y no causalidad, y que la variable de diabetes es declarada.

3.4 Hipótesis 4: la mayoría de los casos de CKF identificados corresponde a blancos no hispánicos.

3.4.1 Definición de la hipótesis:

En esta hipótesis propuesta por la cátedra buscamos verificar si la mayoría de los casos identificados de falla renal crónica dentro del dataset corresponden a personas del grupo étnico de blancos no-hispánicos.

La motivación de evaluar este planteo es analizar cómo se distribuye la etapa más crítica de la enfermedad según la etnicidad de los pacientes, permitiendo comprobar si un único grupo demográfico concentra por sí solo más de la mitad de los cuadros de falla renal detectados en la encuesta.

Para considerar que la hipótesis se cumple, los blancos no hispánicos deberían representar más del 50 % de los casos de CKF identificados. Como explicamos en la estrategia de abordaje, con tan pocos casos no aplicamos un test de

hipótesis, por lo que no planteamos H0 y H1: evaluamos la hipótesis de forma descriptiva.

3.4.2 Estrategia de abordaje:

Para probar esta hipótesis, primero definimos qué registros corresponden a CKF, según la metadata de las variables de los archivos, la falla renal corresponde al Stage 5 del CKD.

Como son los datos confirmados, filtramos únicamente en el dataset por las personas que tienen **ckd_stage** = Stage5, excluyendo de esta forma los registros Unknown (5.607), que no tienen el eGFR calculado.

En este caso decidimos no aplicar un test de hipótesis, esto debido a que el **Test t para una muestra** se basa en la aproximación a la normal del teorema central del límite, que necesita muestras grandes ($n \geq 30$). Con 11 casos no se cumple. Por su parte, el **Chi-cuadrado** necesita que las frecuencias esperadas sean de al menos 5 por categoría. Con 11 casos repartidos en 6 etnias, la frecuencia esperada es de $11 / 6 \approx 1{,}8$, así que tampoco se cumple. Además, este test responde si las etnias tienen la misma cantidad de casos, que es una pregunta distinta a "la mayoría son blancos no hispánicos".

En la notebook, este análisis se encuentra en la sección «Hipótesis 4a», subsecciones «Casos de CKF identificados», «Gráfico: casos de CKF por etnia» y «Por qué no aplicamos un test de hipótesis».

3.4.3 Resultados obtenidos y conclusión:

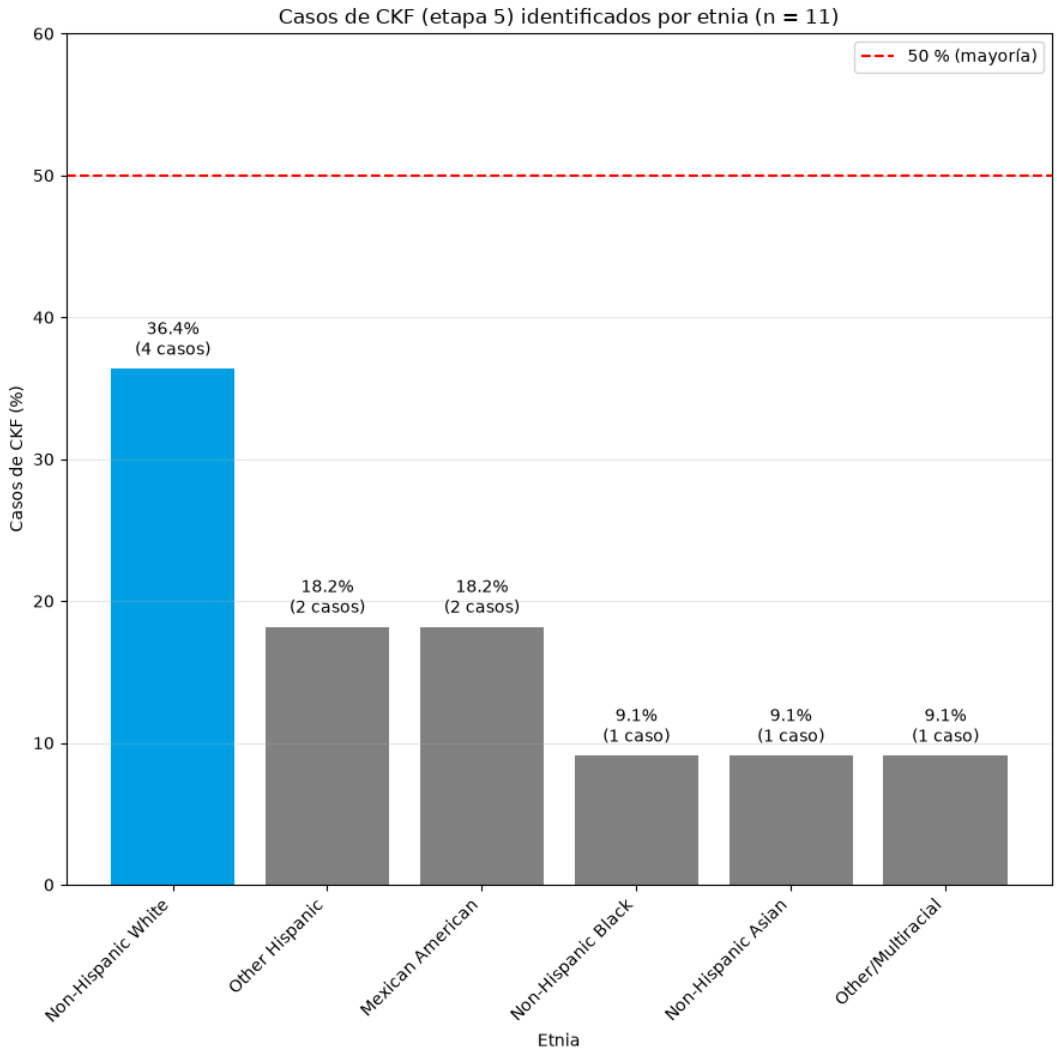


Figura 3.7: Porcentaje de casos de CKF (Stage5) por etnia (n = 11). La línea roja marca el 50 %.

Como podemos ver en la *Figura 3.7* el porcentaje de los casos de CKF correspondiente a blancos no hispánicos es de 36.4%, no llega al 50% necesario para hablar de mayoría. En conclusión, **la hipótesis no se cumple**, igualmente hay una cierta limitación, ya que al trabajar con 11 muestras los porcentajes tienden a ser muy sensibles.

Respecto a esta limitación, es importante aclarar cuánto pesa el tamaño de la muestra en el resultado. Con solo 11 casos de CKF, cada persona representa aproximadamente 9 puntos porcentuales: alcanzaría con que 2 de los 7 casos de otras etnias fueran blancos no hispánicos (6 de 11, es decir, un 54,5 %) para que la conclusión se invirtiera. Por eso, el resultado describe lo que ocurre en esta muestra, pero no nos permite afirmar con firmeza cómo se distribuye la falla renal según la etnia en la población. A esto se suma que los 5.607 registros Unknown no tienen el eGFR calculado, por lo que no sabemos si entre ellos hay otros casos de CKF que podrían cambiar los porcentajes.

3.5 Hipótesis 5: La presión arterial es un factor de riesgo del CKF**.**

3.5.1 Definición de hipótesis:

En esta hipótesis bivariada propuesta por la cátedra buscamos comprobar si la presión arterial constituye un factor de riesgo asociado a la presencia de falla renal crónica.

La motivación clínica para evaluar esta hipótesis es que los riñones cumplen un rol directo en la regulación de la presión sanguínea y, a su vez, la hipertensión arterial daña los vasos sanguíneos renales, siendo una de las causas principales del deterioro severo del filtrado glomerular. Dado que la presión arterial se registra mediante dos mediciones complementarias,la **presión sistólica** y la **presión diastólica**.

Planteamos el análisis evaluando cada una por separado entre las personas con CKF y sin CKF, manteniendo un nivel de significancia de $\alpha = 0.05$:

Para la presión sistólica:

- **H0:** No existen diferencias en la presión arterial sistólica entre personas con CKF y sin CKF.
- **H1:** Existen diferencias en la presión arterial sistólica entre personas con CKF y sin CKF.

Para la presión diastólica:

- **H0:** No existen diferencias en la presión arterial diastólica entre personas con CKF y sin CKF.
- **H1:** Existen diferencias en la presión arterial diastólica entre personas con CKF y sin CKF.

3.5.2 Estrategia de abordaje:

Para encarar esta verificación, filtramos la base quedándonos con los adultos evaluados: personas mayores de 18 años que tienen su **egfr** calculado (excluyendo a los **Unknown**) y que además cuentan con ambas mediciones de presión arterial (**bp_systolic** y **bp_diastolic**) sin valores nulos. Con este criterio obtuvimos una muestra de 5.484 adultos, que dividimos en dos grupos independientes:

- Grupo con CKF (n = 11): personas diagnosticadas en Stage5.
- Grupo sin CKF (n = 5473): el resto de los adultos evaluados.

Primero realizamos un análisis exploratorio visual mediante gráficos de cajas (*boxplots*) para cada presión. Como el grupo con CKF tiene apenas 11 pacientes, superpusimos sobre su caja un gráfico de puntos individuales para visualizar cada observación por separado y ver cuánto influyen los casos extremos en la forma de la caja.

Luego, antes de elegir el test formal, verificamos los supuestos paramétricos:

1. Normalidad: Aplicamos el test de Shapiro-Wilk sobre ambos grupos para las dos presiones y lo complementamos con gráficos QQ plot. Tuvimos especialmente en cuenta que, con solo 11 datos en el grupo CKF, Shapiro-Wilk tiene muy poca potencia estadística.
2. Homocedasticidad: Evaluamos la igualdad de varianzas mediante el test de Levene.

Dado que no se cumplió el supuesto de normalidad, descartamos el test t y aplicamos el test no paramétrico de Kruskal-Wallis, el cual compara las distribuciones a través de sus rangos sin exigir normalidad.

En la notebook, este análisis se encuentra en la sección «Hipótesis 4b», subsecciones «Población y grupos», «Análisis gráfico de la hipótesis», «Supuesto 1: normalidad», «Supuesto 2: homocedasticidad» y «Elección del test».

3.5.3 Resultados obtenidos y conclusiones:

Luego de inspeccionar las variables y gráficos generados encontramos comportamientos opuestos entre ambas presiones.

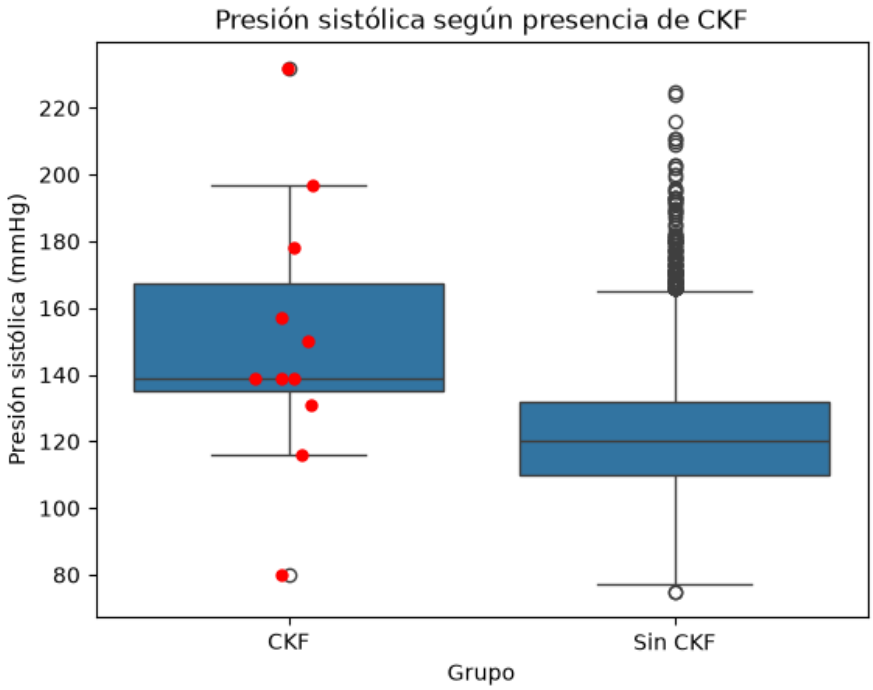


Figura 3.8: Presión sistólica de las personas con y sin CKF. Los puntos rojos son los 11 casos con CKF.

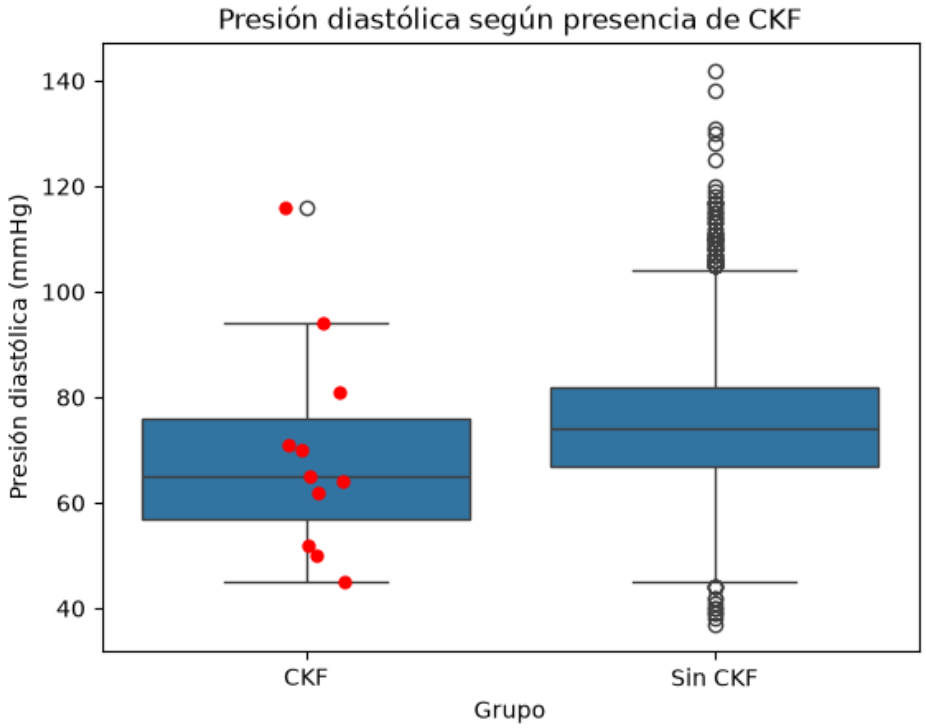


Figura 3.9: Presión diastólica de las personas con y sin CKF. Los puntos rojos son los 11 casos con CKF.

En la **presión sistólica**, la caja del grupo con CKF se ubica claramente más arriba: su mediana es de **139 mmHg** frente a los **120 mmHg** del grupo sin CKF, observándose que la gran mayoría de los puntos rojos superan la mediana de las personas sin falla renal.

En la **presión diastólica** ocurre lo contrario: la mediana del grupo con CKF (**65 mmHg**) es menor que la del grupo sin CKF (**74 mmHg**), mostrando además una dispersión muy grande. En ambos gráficos se aprecian pacientes con valores extremos dentro de los 11 casos con CKF, los cuales tienen mucho peso visual por el tamaño reducido de ese grupo.

Al evaluar el supuesto de **normalidad** con Shapiro-Wilk, obtuvimos:

- **Grupo sin CKF:** Estadístico W = 0.960 (p-valor < 0.001) en sistólica, y Estadístico W = 0.983 (p-valor < 0.001) en diastólica. Al ser ambos p-valores menores a α = 0.05, se rechaza la normalidad. (*Figura 3.11 y 3.13)*
- **Grupo con CKF:** Estadístico W = 0.959 (p-valor = 0.759) en sistólica, y Estadístico W = 0.914 (p-valor = 0.273) en diastólica. Si bien acá no se rechaza H0 por la baja potencia en muestras de n = 11, alcanza con que uno de los dos grupos no sea normal para invalidar los tests paramétricos. (*Figura 3.10 y 3.12*)
- Por su parte, en la prueba de **homocedasticidad** con el test de Levene obtuvimos que en las dos presiones el p-valor es menor a 0.05, por lo tanto **no hay homocedasticidad**: la presión varía mucho más en el grupo CKF que en el grupo sin CKF, como se veía en los boxplots.

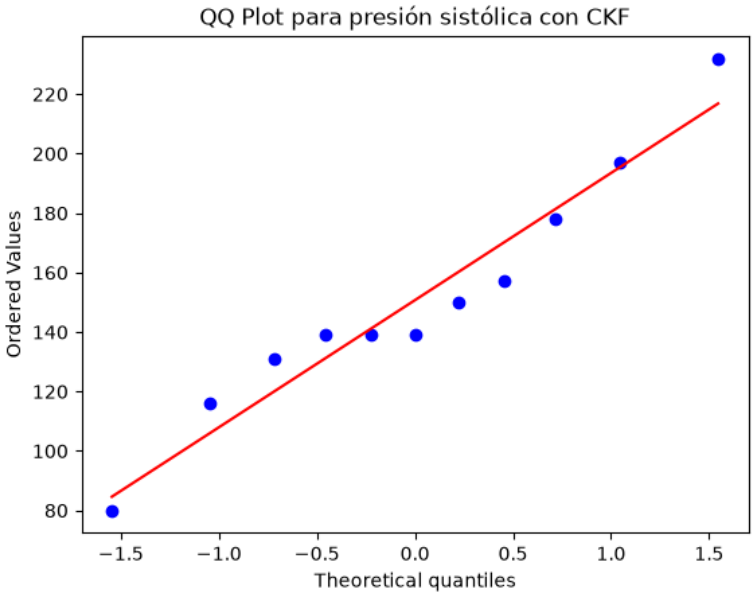


Figura 3.10: QQ plot de la presión sistólica en el grupo con CKF.

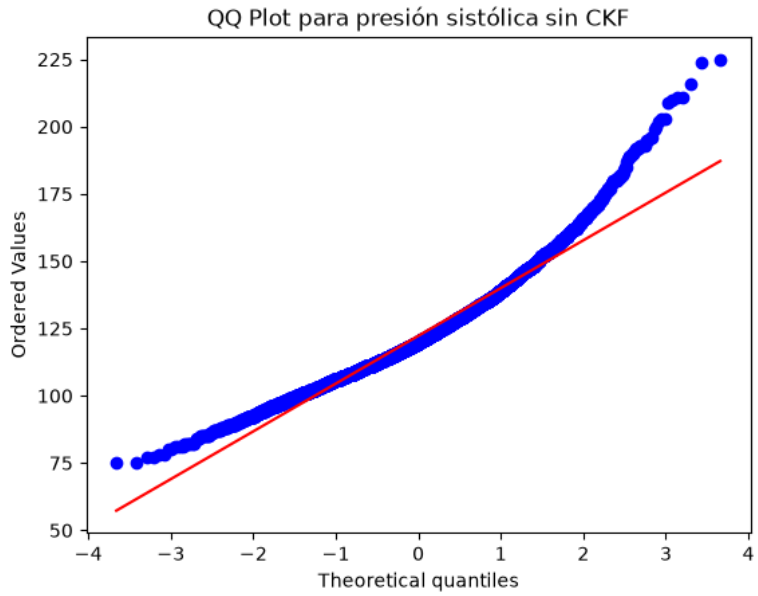


Figura 3.11: QQ plot de la presión sistólica en el grupo sin CKF.

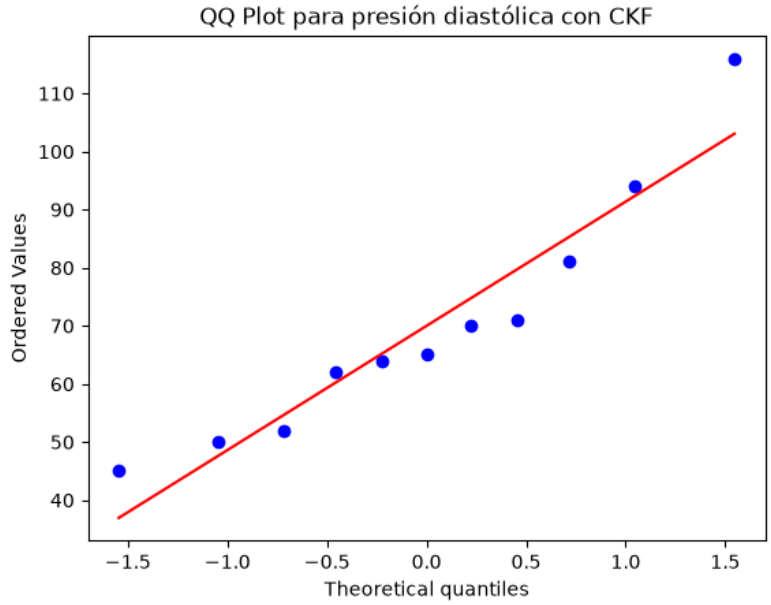


Figura 3.12: QQ plot de la presión diastólica en el grupo con CKF.

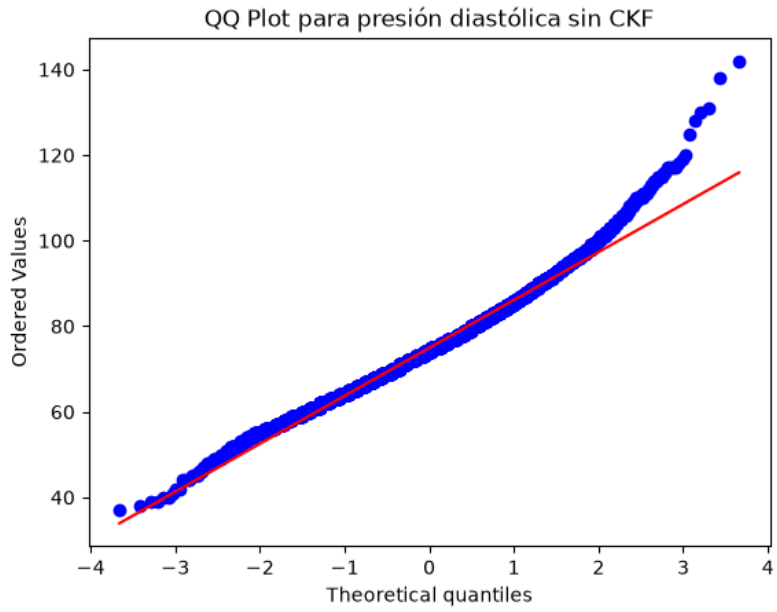


Figura 3.13: QQ plot de la presión diastólica en el grupo sin CKF.

Finalmente, al aplicar el **test de Kruskal-Wallis** para contrastar las hipótesis obtuvimos:

- **Presión sistólica:** Estadístico H = 10.044, **p-valor = 0.0015**. Como el p-valor es menor a α = 0.05, **se rechaza H0**, confirmando que las personas con CKF tienen una presión sistólica significativamente más alta que el resto.
- **Presión diastólica:** Estadístico H = 2.887, **p-valor = 0.0893**. Como el p-valor es mayor a 0,05, no se rechaza **H0**, dando a entender que no hay evidencia de diferencias significativas en la diastólica.

En conclusión, **la hipótesis se confirma parcialmente, a través de la presión arterial sistólica**: existe evidencia estadística para afirmar que la presión sistólica elevada está vinculada con la falla renal crónica.

Sin embargo, este resultado hay que tomarlo con cautela por el tamaño del grupo con CKF. Al tener solo 11 personas frente a las 5.473 del grupo sin CKF, el análisis tiene poca potencia estadística, es decir, poca capacidad para detectar una diferencia aunque exista. Esto afecta a los dos resultados. Por un lado, que la presión diastólica no haya dado significativa no demuestra que no haya diferencia, sino que con 11 casos no tenemos evidencia suficiente para detectarla. Por otro lado, en un grupo tan chico cada persona representa cerca del 9 % del grupo, por lo que uno o dos casos extremos, como el paciente con 232/116 mmHg o el de 80/45 mmHg, pueden mover bastante las medianas. El test de Kruskal-Wallis, al trabajar con rangos, reduce el efecto de esos valores extremos, pero no soluciona la falta de datos.

Además, como se trata de datos observacionales, el resultado muestra una asociación entre la presión sistólica y la falla renal, pero no que una cause a la otra: la hipertensión daña el riñón y, a su vez, la enfermedad renal también eleva la presión.

3.6 Hipótesis 6: Existe un vínculo directo entre la edad, el sexo, el BMI, la presión arterial, la diabetes, el tabaquismo y el nivel socioeconómico con la probabilidad de presentar CKD.

3.6.1 Definición de la hipótesis:

En esta última hipótesis multivariada propuesta por la cátedra, analizamos si existe un vínculo directo que nos permita explicar la probabilidad de presentar CKD (**ckd_present**) a partir de las variables edad (**age**), sexo (**gender**), BMI (**bmi**), presión arterial (**bp_systolic** y **bp_diastolic**), diabetes (**diabetes_diagnosed**), tabaquismo (**ever_smoked**) y nivel socioeconómico (**poverty_income_ratio** y **education_level**).

Lo que motiva este planteo es que, en la práctica médica, la enfermedad renal crónica rara vez aparece por una única causa aislada, sino por la combinación de varios factores demográficos, metabólicos y de estilo de vida que actúan al mismo tiempo. Evaluar todas estas variables juntas nos permite identificar cuáles tienen un peso directo real sobre la presencia de CKD.

H0: Ninguna de las variables analizadas tiene un vínculo lineal significativo con la probabilidad de presentar CKD ($\beta1 = \beta2 = ... = 0$).

H1: Al menos una de las variables analizadas presenta un vínculo directo y estadísticamente significativo con la probabilidad de presentar CKD (al menos un $\beta i \neq 0$).

3.6.2 Estrategia de abordaje:

Para abordar el análisis primario de la hipótesis, tuvimos que hacer algunos cambios sobre las variables utilizadas.

En primera instancia, primero excluimos los registros con valor unknown de ckd_stage, además realizamos algunas transformaciones a algunas variables:

- **Sexo (**sexo_masculino**):** Representamos el género en una única columna codificada con 1 (hombre) y 0 (mujer). Hicimos esto específicamente para evitar la multicolinealidad perfecta.
- **Tabaquismo (**fumo_alguna_vez**):** Utilizamos únicamente la variable ever_smoked (1 si fumó al menos 100 cigarrillos en su vida y 0 si no), lo cual nos da un indicativo más sólido de si el paciente tiene tendencia a presentar CKD por daño acumulado de haber fumado en el pasado, independientemente de si fuma ahora.
- **Diabetes (**diabetes**):** Codificamos con 1 a quienes tienen diabetes diagnosticada y con 0 a quienes no.

Eliminando las filas con datos faltantes nos quedaron **4.560 adultos de 20 años o más** (debido a que education_level se releva a partir de esa edad), donde el 48,16% presenta CKD.

Como primer paso exploratorio utilizamos una matriz de correlación, luego verificamos formalmente que no hubiera multicolinealidad entre predictores calculando el Factor de Inflación de la Varianza (VIF).

Por último estandarizamos todas las variables llevándolas a media 0 y desvío 1. De esta forma igualamos las escalas para ajustar un modelo de regresión logística sobre ckd_present y comparar el peso de cada variable mediante sus Odds Ratios.

En el análisis exploratorio de la matriz de correlación obtuvimos este resultado (Figura 3.14):

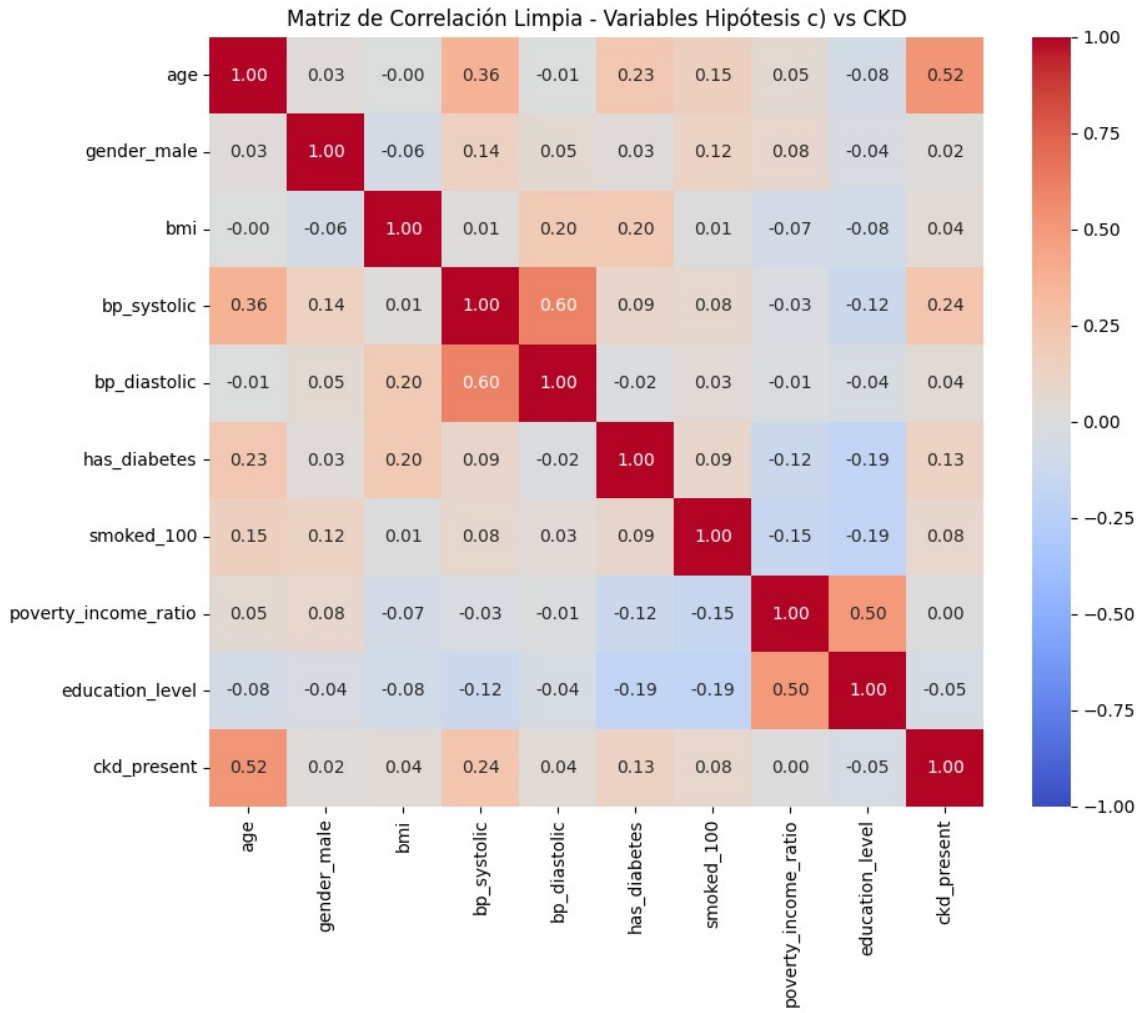


Figura 3.14: Matriz de correlación entre ckd_present y las variables de la hipótesis 4c.

En la notebook, este análisis se encuentra en la sección «Hipótesis 4c», subsecciones «Variable objetivo», «Preparación de las variables», «Análisis exploratorio: matriz de correlación», «Multicolinealidad: VIF», «Estandarización de las variables», «Odds ratios» y «Gráfico de los odds ratios».

3.6.3 Resultados obtenidos y discusión:

Como podemos observar, las variables en general no tienen una relación fuerte con las demás, únicamente las que destacan son:

Nivel de educación e ingreso familiar: Se observa una correlación positiva de 0.50 por lo que a medida que sube el ingreso familiar, también lo hace el nivel de educación(lógicamente).

Ckd_present con edad: Con una correlación de 0.52, es lógico pensar que las personas mas adultas tienen una probabilidad mayor de contraer CKD.

Bp_systolic con **bp_diastolic**: Al ser ambas presiones del corazón, tiene sentido que tengan una correlación positiva asociada.

Al verificar el supuesto de ausencia de multicolinealidad mediante el **VIF**, comprobamos que todas las variables arrojaron valores menores a 2,1 (muy por debajo del umbral crítico de 5), lo que confirma que no hay multicolinealidad y que es válido incluir juntas las dos presiones y las dos variables socioeconómicas.

Una vez hecha la estandarización y corrida la regresión logística, transformamos los coeficientes en **Odds Ratios (OR)** aplicando la exponencial, los cuales indican cuánto se multiplican las chances de tener CKD por cada desvío estándar que aumenta la variable. Obtuvimos un Pseudo $R^2 = 0.223$ y los siguientes resultados: (*Tabla 2 y Figura 3.15*)

Dep. Variable:	ckd_present	**No. Observations:**	4560
Model:	Logit	**Df Residuals:**	4550
Method:	MLE	**Df Model:**	9
Date:	Tue, 10 Nov 2026	**Pseudo R-squ.:**	0.2228
Time:	14:18:10	**Log-Likelihood:**	-2454.2
converged:	True	**LL-Null:**	-3157.7
Covariance Type:	nonrobust	**LLR p-value:**	2.477e-297

	coef	std err	z	P> |z|	[0.025	0.975]
const	-0.1509	0.036	-4.236	0.000	-0.221	-0.081
age	1.2693	0.047	26.922	0.000	1.177	1.362
sexo_masculino	-0.0056	0.036	-0.156	0.876	-0.076	0.064
bmi	0.1135	0.037	3.095	0.002	0.042	0.185
bp_systolic	0.1274	0.052	2.462	0.014	0.026	0.229
bp_diastolic	0.0496	0.049	1.019	0.308	-0.046	0.145
diabetes	0.0381	0.036	1.071	0.284	-0.032	0.108
fumo_alguna_vez	0.0113	0.036	0.315	0.753	-0.059	0.082
poverty_income_ratio	-0.0490	0.041	-1.199	0.230	-0.129	0.031
education_level	0.0283	0.041	0.688	0.491	-0.052	0.109

Tabla 2: Resumen de la regresión logística para ckd_present (hipótesis 4c).

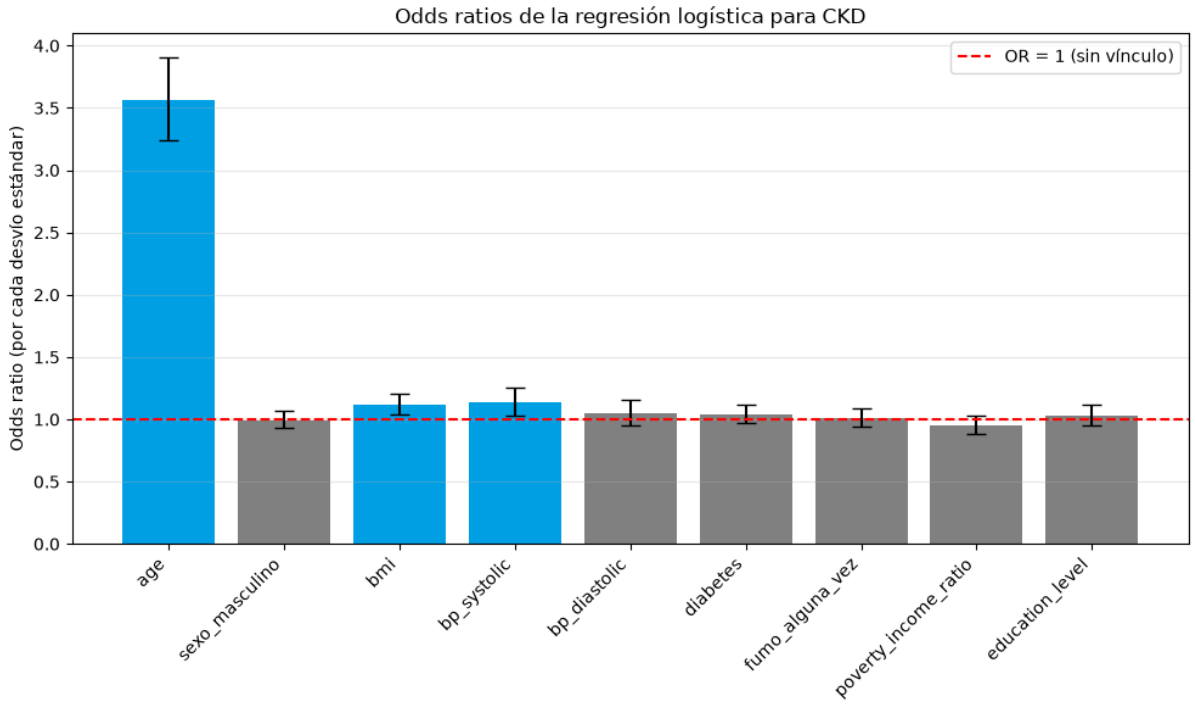


Figura 3.15: Odds ratios (por desvío estándar) del modelo de CKD, con su IC del 95 %. En azul, las variables significativas.

Como podemos observar, obtuvimos un **pseudo R^2** bajo y muchas variables que no son significativas en el aporte a la regresión logística, esto se debe a varios factores:

Primero, tenemos variables como **gender** (convertida en una columna numerica sexo_masculino, p-valor = 0.876), que ya se utiliza dentro de la fórmula clínica para calcular el egfr con el fin de corregir las diferencias de masa muscular entre hombres y mujeres. Por lo tanto, incluir el genero por sí solo no aporta diferencia significativa sobre la probabilidad de presentar CKD una vez considerados los demás factores.

Del mismo modo, encontramos que **bp_diastolic** pierde significancia estadística (p-valor = 0.308) al estar presente **bp_systolic** en el modelo multivariado. Esto ocurre porque ambas presiones están relacionadas entre sí (correlación de 0.60, aunque sin llegar a la multicolinealidad según el VIF): una vez incluida la sistólica, la diastólica casi no agrega información nueva. Además, la sistólica es el factor de riesgo vascular predominante. Por su parte, las variables socioeconómicas (**poverty_income_ratio** con p-valor = 0.230 y **education_level** con p-valor = 0.491) y el tabaquismo (**fumo_alguna_vez** con

p-valor = 0.753) tampoco muestran un efecto directo significativo al controlar por la edad y las condiciones clínicas.

En el caso de la **diabetes** (p-valor = 0.284), no resulta significativa sobre la etiqueta general **ckd_present** por dos motivos: por un lado, parte de su asociación metabólica es capturada por el **bmi** y la hipertensión sistólica que ya están dentro del modelo. Por otro lado, la mayoría de los casos positivos de **ckd_present** corresponden a **Stage2**, lo que diluye el efecto específico que tiene la diabetes sobre la albuminuria (**Stage1**) y etapas avanzadas.

Respecto al **Pseudo R^2** y su valor bajo, es completamente lógico debido a que estamos evaluando factores de riesgo demográficos y de hábitos sobre tener CKD, cuando en realidad el verdadero determinante que nos puede decir si tiene CKD o no son los análisis clínicos como el cálculo de **eGFR** o el cálculo de albuminuria **ACR**.

La hipótesis se valida parcialmente ya que solo la edad, el BMI y la presión arterial sistólica mantienen un vínculo directo con la probabilidad de presentar CKD, mientras que el resto de las variables no muestran un efecto significativo una vez que se consideran todas juntas.

4. Conclusiones:

En el presente trabajo se analizó el conjunto de datos CKD-NHANES (2021-2023) con el objetivo de caracterizar la enfermedad renal crónica y evaluar estadísticamente diversos factores demográficos, antropométricos, clínicos y de estilo de vida asociados a su desarrollo.

A partir de la evaluación de las hipótesis planteadas, se determinó que la proporción de fumadores activos en la población adulta testeada supera el valor de referencia nacional informado por el CDC (Centros para el Control y la Prevención de Enfermedades). También encontramos que la capacidad de filtrado (eGFR) difiere entre hombres y mujeres, aunque la diferencia es tan chica que no tiene relevancia clínica, y que las personas con falla renal crónica presentan una presión sistólica más alta que el resto, mientras que en la diastólica no hallamos diferencias. A su vez, los modelos de regresión logística aplicados permitieron corroborar que la edad, la presión arterial sistólica y el índice de masa corporal (**BMI**) presentan una relación directa y estadísticamente significativa con la presencia de CKD. En términos clínicos, se observó que, si bien la diabetes no muestra un efecto directo sobre el indicador general de enfermedad debido a la alta proporción de estadios leves

asociados al envejecimiento, sí se encuentra fuertemente vinculada al daño renal temprano manifestado a través de la albuminuria (**ACR**), lo cual resalta la relevancia de los biomarcadores urinarios en fases iniciales. Por otra parte, el análisis de los casos severos de falla renal (**Stage 5**) evidenció una distribución heterogénea entre los diferentes grupos étnicos, sin registrarse una prevalencia mayoritaria de un grupo en particular.

Finalmente, cabe señalar como limitaciones del estudio el acotado tamaño muestral en los estadios más avanzados (solo 11 casos de CKF), que le quita potencia a los análisis sobre la falla renal, y que, al tratarse de datos observacionales, los resultados muestran asociaciones y no permiten establecer relaciones de causalidad directa. Igualmente no hay que descartar los hallazgos obtenidos, los cuales confirman la utilidad de las herramientas de análisis de datos para analizar la multifactorialidad de la enfermedad renal crónica, aportando evidencia significativa para el diagnóstico temprano y las estrategias de prevención.

Referencias:

National Center for Health Statistics (NCHS). (2023). *National Health and Nutrition Examination Survey (NHANES) 2021-2023*. Centers for Disease Control and Prevention (CDC).

https://wwwn.cdc.gov/nchs/nhanes/continuousnhanes/default.aspx?Cycle=2021-2023

Centers for Disease Control and Prevention (CDC). (2021). *Cigarette Smoking Among U.S. Adults — 2021*. U.S. Department of Health and Human Services. https://www.cdc.gov/cdi/indicator-definitions/tobacco.html